

A função custo $J(\theta)$ para uma rede neural com K classes, n features, m input rows, L layers, com s_l neurônios em cada layer, e na qual aplicarmos regressão logística, será dada por:

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m \sum_{k=1}^K y_k^{(i)} \cdot \log(h_\theta(x^{(i)}))_k + (1 - y_k^{(i)}) \cdot \log(1 - h_\theta(x^{(i)}))_k \right] + \frac{\lambda}{2m} \sum_{l=1}^{L-1} \sum_{j=1}^{s_l} \sum_{j=1}^{s_{l+1}} (\theta_j^{(l)})^2$$

// aplicando em Octave:

→ given $m, K, L, y(m, K), h = a^{(L)}(K, m)$,

$J = 0$;

for $i = 1:m$

for $k = 1:K$

$$J = (-1/m) * (y(i, k) \cdot \log(a(k, i)) + (1 - y(i, k)) \cdot \log(1 - a(k, i))) + J;$$

end for

end for

// próxima parte calculará o custo levando em conta as regularizações dos pesos
 // parâmetros.

OBS: se $K=1$ temos apenas 1 classe e $y=0$ ou 1 , o que chamamos de problema de classificação binária. No entanto, se $K \geq 3$, temos um problema de classificação multiclass (multi-class classification).
OBS2: se $K=2$ pode-se reduzir ao problema binário.

vetor c/ # neurônios em cada camada
~~vetor c/ # neurônios em cada camada~~ : 280 //
~~vetor c/ # neurônios em cada camada~~ : 280 //
~~vetor c/ # neurônios em cada camada~~ : 280 //

$\underbrace{s(L)}$, $\underbrace{\lambda}$, e $\underbrace{\Theta}_{\text{maior # de linhas em uma matriz } \theta^{(l)}}(\max(s)+1, m+1, L-1)$
 \uparrow maior # de linhas em uma matriz $\theta^{(l)}$ // \uparrow maior # de colunas em uma matriz $\theta^{(l)}$ // \uparrow maior # de colunas em uma matriz $\theta^{(l)}$ //

- se for necessário obter os pesos
 - se for necessário obter os pesos entre os
 - se for necessário obter os pesos entre os